

Relatório Técnico

Capa

Título: Integração de dados macroeconômicos brasileiros e mercado de criptomoedas

Natureza: Relatório técnico

Autor(es): Artur Napoles, Guilherme Carrico, Gustavo Dutra e Rafael Lucena

Disciplina: Data Integration (2026.1)

Instituição: ESPM - Sistemas de Informação

Professor: Prof. Me. Andre Insardi

Sumário executivo

Este relatório apresenta o CryptoETL, um pipeline de integração de dados que combina séries macroeconômicas do Banco Central do Brasil (BCB) com dados de mercado de criptoativos da CoinGecko. O objetivo é permitir análises sobre o impacto de variáveis macroeconômicas, como dólar, SELIC e IPCA, no comportamento de ativos digitais como BTC, ETH, SOL e BNB.

A solução foi implementada em Python, orquestrada com Apache Airflow e persistida em PostgreSQL, com infraestrutura baseada em Docker. O processo contempla extração, tratamento, padronização temporal, enriquecimento com métricas de volatilidade e consolidação em tabela analítica diária. Na execução validada, o projeto terminou com 19 testes aprovados, 1460 linhas consolidadas e 0 nulos em `data_brazil`, o que confirma a consistência operacional da entrega.

O resultado final é uma base pronta para consultas de valor, com rastreabilidade, idempotência por meio de UPSERT e evidências reais de execução em Airflow, dashboard Streamlit, PostgreSQL e testes automatizados.

Palavras-chave: integração de dados; banco de dados; Airflow; PostgreSQL; criptomoedas.

Sumário

1. Descrição do problema e justificativa do tema
2. Arquitetura da solução
3. Fontes de dados e regras de transformação
4. Modelagem do banco de dados
5. Descrição das DAGs do Airflow
6. Validações de qualidade implementadas
7. Resultados

- 8. Execução, testes e evidências operacionais
- 9. Limitações e possíveis evoluções
- 10. Referências
- 11. Conclusão
- 12. Anexos

1. Descrição do problema e justificativa do tema

O mercado de criptoativos apresenta elevada volatilidade e é influenciado por fatores macroeconômicos. Para viabilizar análises de correlação e comportamento, torna-se necessário integrar fontes heterogêneas, com granularidades distintas e diferentes formatos temporais.

O tema é relevante por conectar dados financeiros oficiais do Brasil com ativos digitais globais, fornecendo insumos para estudos de risco, impacto cambial e potencial proteção inflacionária.

2. Arquitetura da solução

A solução segue um pipeline ETL em três camadas: extração, transformação e carga. O fluxo foi organizado para garantir idempotência, rastreabilidade e escalabilidade operacional.

```
flowchart LR
    subgraph APIs
        BCB[BCB API\nDólar / SELIC / IPCA]
        CG[CoinGecko API\nBTC / ETH / SOL / BNB]
    end

    BCB --> EXB[Extract BCB]
    CG --> EXC[Extract CoinGecko]
    EXB --> BCBT[(bcb_indicators)]
    EXC --> CRYPT[(crypto_market)]
    BCBT --> TR[Transform + Join]
    CRYPT --> TR
    TR --> CONS[(daily_consolidated)]
```

3. Fontes de dados e regras de transformação

3.1 Fontes

| Fonte | Itens utilizados |

| --- | --- |

| BCB (SGS) | Dólar (PTAX), SELIC e IPCA |

| CoinGecko | Bitcoin, Ethereum, Solana e Binance Coin |

3.2 Regras de transformação

- Conversão de datas do BCB: DD/MM/YYYY para DATE.
- SELIC anualizada: $((1 + \text{selic_diaria}/100)^{252} - 1) * 100$.
- IPCA mensal aplicado ao calendário diário com forward fill.
- CoinGecko: timestamps em milissegundos para data diária.
- Agregação diária: preço como último valor do dia e volume consolidado.
- Variação diária: `pct_change_1d`.
- Volatilidade de 7 dias: desvio padrão da variação diária.
- Preço em BRL: `price_usd * dolar_brl`.

4. Modelagem do banco de dados

A modelagem utiliza três tabelas principais e uma tabela de logs:

```
| Tabela | Papel |
| --- | --- |
| bcb_indicators | Base bruta macroeconômica |
| crypto_market | Base bruta de criptoativos |
| daily_consolidated | Tabela analítica consolidada |
| pipeline_run_log | Rastreamento de execuções |
```

```
erDiagram
    BCB_INDICATORS {
        int id PK
        date reference_date
        varchar indicator
        numeric valor
        timestamp ingested_at
    }

    CRYPTO_MARKET {
        int id PK
        varchar coin_id
        date reference_date
        numeric price_usd
        numeric market_cap_usd
        numeric volume_24h_usd
        timestamp ingested_at
    }

    DAILY_CONSOLIDATED {
        int id PK
        date reference_date
        varchar coin_id
        numeric price_usd
        numeric price_brl
        numeric market_cap_usd
        numeric volume_24h_usd
    }
```

```

■ numeric pct_change_1d
■ numeric volatility_7d
■ numeric dolar_brl
■ numeric selic_daily_rate
■ numeric selic_annual_rate
■ numeric ipca_monthly
■ timestamp created_at
■ }

■ PIPELINE_RUN_LOG {
■ int id PK
■ varchar dag_id
■ varchar task_id
■ varchar source
■ varchar status
■ int rows_inserted
■ text error_message
■ timestamp started_at
■ timestamp finished_at
■ }

■ BCB_INDICATORS ||--o{ DAILY_CONSOLIDATED : enriches
■ CRYPTO_MARKET ||--o{ DAILY_CONSOLIDATED : enriches

```

Fato principal: daily_consolidated

Dimensões implícitas: data (reference_date) e ativo (coin_id)

5. Descrição das DAGs do Airflow

As DAGs foram implementadas com PythonOperator, executadas diariamente (@daily), com catchup=False e LocalExecutor para simplificar a execução local.

- dag_extract_bcb (extract_bcb): executa run_bcb_extraction e grava em bcb_indicators.
- dag_extract_coingecko (extract_crypto): executa run_coingecko_extraction e grava em crypto_market.
- dag_consolidate (consolidate_daily_tables): executa run_consolidation e grava em daily_consolidated.

A execução recomendada é BCB -> CoinGecko -> Consolidação. Como cada etapa faz UPSERT, reprocessamentos são seguros.

6. Validações de qualidade implementadas

| Validação | Descrição |

| --- | --- |

| Idempotência | UPSERT com chave única por data e indicador/ativo |

| Tratamento de nulos | Conversão para numérico com errors="coerce" |

| Consistência temporal | Padronização de datas e normalização para dia |

| Forward fill | IPCA mensal aplicado aos dias do período |

| Integridade lógica | Consolidação depende das duas fontes |

7. Resultados

A seguir, estão três consultas de valor executadas no PostgreSQL.

7.1 Correlação dólar x BTC em BRL

```
SELECT corr(price_brl, dolar_brl) AS corr_btc_dolar
FROM daily_consolidated
WHERE coin_id = 'bitcoin';
```

Resultado: corr_btc_dolar = 0.745440789641126

7.2 Média de volatilidade por ativo

```
SELECT
  coin_id,
  avg(volatility_7d) AS avg_vol_7d
FROM daily_consolidated
GROUP BY coin_id
ORDER BY avg_vol_7d DESC;
```

Resultado:

| coin_id | avg_vol_7d |

| --- | ---: |

| solana | 3.5336377410468320 |

| ethereum | 3.3109272727272727 |

| binancecoin | 2.3327939393939394 |

| bitcoin | 1.9717239669421488 |

7.3 SELIC anualizada vs retorno médio diário

```
SELECT
  coin_id,
  avg(pct_change_1d) AS avg_daily_return,
  avg(selic_annual_rate) AS avg_selic
FROM daily_consolidated
GROUP BY coin_id
ORDER BY avg_daily_return DESC;
```

Resultado:

```
| coin_id | avg_daily_return | avg_selic |
| --- | ---: | ---: |
| ethereum | 0.03474917582417582418 | 14.8287417863013699 |
| binancecoin | 0.03057967032967032967 | 14.8287417863013699 |
| bitcoin | -0.04656565934065934066 | 14.8287417863013699 |
| solana | -0.10510082417582417582 | 14.8287417863013699 |
```

8. Execução, testes e evidências operacionais

O projeto foi validado em ambiente local com Docker, PostgreSQL, Airflow e dashboard Streamlit. As etapas principais executadas foram:

- Subida dos containers com `docker compose up -d`.
- Execução das DAGs de extração e consolidação no Airflow.
- Verificação da tabela `daily Consolidated` no PostgreSQL.
- Abertura do dashboard Streamlit para consulta dos KPIs e gráficos.
- Execução dos testes automatizados com `python -m pytest -q`.

O dashboard disponibiliza indicadores consolidados, séries temporais e gráficos de comparação entre ativos cripto e variáveis macroeconômicas, servindo como camada final de consumo da base tratada.

As validações de qualidade cobrem nulidade, duplicidade e consistência de faixa, reduzindo o risco de carga de dados inconsistentes.

Saída resumida da apresentação

```
[4/6] Validando banco...
count
-----
■ 514

count
-----
■1460

count
-----
■1460

[5/6] Rodando testes...
collected 19 items
tests\test_bcb_extractor.py ..
tests\test_bcb_transformer.py .....
tests\test_coingecko_extractor.py ..
tests\test_crypto_transformer.py .....
tests\test_data_quality.py ....
===== 19 passed in 2.47s =====
```

[6/6] Gerando PDF...

PDF gerado em: C:\Users\gustavo.telles\Desktop\CryptoETL\RELATORIO_TECNICO.pdf

Evidências de testes

```
===== test session starts =====
platform win32 -- Python 3.11.0, pytest-7.4.3, pluggy-1.6.0
rootdir: C:\Users\gustavo.telles\Desktop\CryptoETL
configfile: pytest.ini
testpaths: tests
collected 19 items

tests\test_bcb_extractor.py ..
tests\test_bcb_transformer.py .....
tests\test_coingecko_extractor.py ..
tests\test_crypto_transformer.py .....
tests\test_data_quality.py ....

===== 19 passed in 2.47s =====
```

Trecho de validação da consolidação

1460

0

O primeiro valor confirma o total de linhas consolidadas retornado por `run_consolidation`. O segundo valor confirma que não restaram nulos em `dolar_brl` na tabela final.

Evidências de banco

```
coin_id,cnt
ethereum,365
binancecoin,365
bitcoin,365
solana,365
```

Interpretação: a tabela `daily_consolidated` possui 365 registros para cada ativo, confirmando a consolidação diária do período analisado.

Trecho do carregamento Airflow

- ✓ Extração BCB concluída: 514 registros no total
- ✓ Extração CoinGecko concluída: 1460 registros no total
- ✓ Consolidação concluída
- ✓ Validações BCB aprovadas
- ✓ Validações CoinGecko aprovadas

Esse trecho mostra o comportamento fim a fim da execução no Airflow, com as duas extrações e a consolidação final completadas com sucesso.

Prints do dashboard e do Airflow

Figura 1 - Visão geral do dashboard





Figura 2 - Correlação dólar x Bitcoin




Figura 3 - Print completo do dashboard



Figura 4 - Home do Airflow





9. Limitações e possíveis evoluções

- Dependência de APIs públicas sujeitas a rate limit e indisponibilidade.
- Ausência de cache histórico local para reduzir chamadas.
- Escopo limitado a 4 ativos e 3 indicadores.

Evoluções sugeridas:

- Adicionar mais ativos e indicadores, como PIB e desemprego.
- Criar camadas históricas, como Data Lake ou S3.
- Agendar alertas e dashboards automatizados com Metabase ou Power BI.
- Implementar testes automatizados de qualidade e schema drift.

10. Referências

- BANCO CENTRAL DO BRASIL. Sistema Gerenciador de Séries Temporais (SGS): série 1 - dólar PTAX. Disponível em: <<https://api.bcb.gov.br/dados/serie/bcdata.sgs.1/dados>>. Acesso em: 10 maio 2026.
- BANCO CENTRAL DO BRASIL. Sistema Gerenciador de Séries Temporais (SGS): série 11 - taxa SELIC. Disponível em: <<https://api.bcb.gov.br/dados/serie/bcdata.sgs.11/dados>>. Acesso em: 10 maio 2026.
- BANCO CENTRAL DO BRASIL. Sistema Gerenciador de Séries Temporais (SGS): série 433 - IPCA. Disponível em: <<https://api.bcb.gov.br/dados/serie/bcdata.sgs.433/dados>>. Acesso em: 10 maio 2026.

- COINGECKO. API v3 - Market Chart. Disponível em:
<https://api.coingecko.com/api/v3/coins/bitcoin/market_chart>. Acesso em: 10 maio 2026.
- APACHE AIRFLOW. Apache Airflow documentation. Disponível em:
<<https://airflow.apache.org/docs/>>. Acesso em: 10 maio 2026.
- POSTGRESQL GLOBAL DEVELOPMENT GROUP. PostgreSQL documentation. Disponível em:
<<https://www.postgresql.org/docs/>>. Acesso em: 10 maio 2026.

11. Conclusão

O projeto atende ao objetivo proposto de integrar dados macroeconômicos brasileiros com dados do mercado de criptomoedas em uma arquitetura reprodutível, automatizada e observável. A solução entrega extração modular, consolidação em PostgreSQL, orquestração com Airflow, dashboard analítico, logging estruturado, validações de qualidade e testes automatizados.

Como resultado, a base `daily Consolidated` fica pronta para análises de correlação, volatilidade e comportamento temporal entre ativos digitais e variáveis econômicas, oferecendo uma entrega completa para avaliação acadêmica.

12. Anexos

- Diagrama de arquitetura (Mermaid)
- Diagrama ER / modelo dimensional (Mermaid)
- Prints do Airflow (grid/graph/log) e das consultas SQL

Evidências visuais

As capturas foram salvas em `reports/screenshots/` durante a validação do dashboard.

Evidências Airflow

As capturas provam a orquestração e execução das DAGs no Airflow.

Evidências de testes e banco

Os artefatos abaixo registram a validação executada localmente:

- `reports/screenshots/pytest_output.txt`
- `reports/screenshots/db_counts.csv`

Artefato da apresentação

O arquivo `reports/screenshots/presentation_text.txt` registra o conteúdo textual da execução da apresentação e complementa os prints visuais e os logs de teste.

Conteúdo dos artefatos

``reports/screenshots/pytest_output.txt``

```
===== test session starts =====
platform win32 -- Python 3.11.0, pytest-7.4.3, pluggy-1.6.0
rootdir: C:\Users\gustavo.telles\Desktop\CryptoETL
configfile: pytest.ini
testpaths: tests
collected 19 items

tests\test_bcb_extractor.py ..
tests\test_bcb_transformer.py .....
tests\test_coingecko_extractor.py ..
tests\test_crypto_transformer.py .....
tests\test_data_quality.py ....

===== 19 passed in 1.61s =====
```

``reports/screenshots/db_counts.csv``

```
coin_id,cnt
ethereum,365
binancecoin,365
bitcoin,365
solana,365
```